

Consignes du projet - étape 1

- Écrire un premier script Python permettant d'aspirer (collecter) les entités médicales de type **noms de médicaments par substance active** de A à Z, à partir des 26 pages HTML du dossier « VIDAL » que je vous ai mis en pièce-jointe.
- Générer en sortie un dictionnaire au format **.dic** (format DELAF vu en cours 4) encodé en **UTF-16 LE avec BOM** (UCS-2 LE BOM).
- Ce dictionnaire **doit s'appeler** « **subst.dic** » et doit contenir les noms de médicaments par substance active des 26 pages HTML du dossier « VIDAL ».
- Chaque entrée lexicale de ce dictionnaire doit être suivie par les informations (codes) **„N+subst**
- L'information **N** est de type grammatical et l'information **subst** est de type sémantique.
- Vous devez donc obtenir une sortie ayant le format DELAF-UNITEX suivant :
 - **abacavir,„N+subst**
 - **abatacept,„N+subst**
 - **abciximab,„N+subst**
 - **abiratérone,„N+subst**
 - **.....**
- L'aspiration doit être faite en local sur votre machine. Pour ce faire, vous devrez installer une plateforme de développement Web, comme par exemple : **WampServer**, **XAMPP** ou **EasyPHP-DevServer**, qui contiennent, entre autres, un serveur Web Apache.

Remarque : L'encodage UTF-8 sans BOM des pages HTML du dossier « VIDAL » ne doit pas être modifié.

- Ensuite, donner la possibilité à l'utilisateur de déterminer l'intervalle des pages à traiter, en respectant le format : B-H, E-S ou A-W, etc. Cet intervalle **est le premier argument du premier script Python** « aspirer.py ».

Projet « Extraction d'information »

- Générer un fichier nommé « infos.txt » contenant :
 - le nombre d'entités médicales de type noms de médicaments par substance active du dictionnaire « subst.dic » généré préalablement, pour chaque lettre de l'alphabet ;
 - et le nombre total d'entités médicales de type noms de médicaments par substance active de ce dictionnaire.
- Donner également la possibilité à l'utilisateur de saisir le « port http », qui est précisé dans le « fichier de configuration du serveur Web Apache ». Ce port est le deuxième argument du **premier script Python**.
- Autrement dit, une fois que vous avez choisi votre port **manuellement** dans ce fichier de configuration, vous le mettez ensuite comme deuxième argument à votre script « aspirer.py ». Ce script doit exploiter ce port pour accéder à l'URL des 26 pages HTML du dossier VIDAL, qui seront accessibles en local.

Remarque : Le port http par défaut est le port « **80** ».

Remarque : Ce premier script python « aspirer.py » **doit impérativement avoir 2 arguments : l'intervalle d'aspiration et le port http.**

Remarque : votre script python **ne doit pas modifier (écrire dans) le fichier de configuration Apache lors de l'aspiration.**